

Fly.io — o que é, o que custa e o que precisa saber antes de decidir

Levantado em 19/08/2026 direto da documentação oficial de preços, sizing, CPU, volumes e gestão de custo. A decisão está no [ADR-015](#); este doc é a explicação de apoio.

 **Revisado em 19/08 após parecer externo (GPT).** A primeira versão continha um erro grave — afirmava que dava para configurar limite de gasto e alerta, o que **não existe no Fly** — e usava preço da região errada. Sete correções aplicadas; as principais estão marcadas com  **Corrigido** ao longo do texto.

Em uma frase

Micro-VMs cobradas por segundo, em **São Paulo**, rodando a nossa imagem Docker, por **~\$7,50/mês**, sem precisar cuidar de máquina Linux.

 **Corrigido:** a primeira versão dizia "*sem ninguém precisar administrar servidor*", o que vende demais. O que sai da nossa conta é o **servidor** — SO, patches, firewall, Coolify. **Continuam nossos:** deploy, configuração da Machine, volume, segredos, métricas e resposta a incidente. É bem menos trabalho que uma VPS, não é zero.

1. O modelo de cobrança: não existe plano

É **pay-as-you-go puro**. Nas palavras deles: "*Plans get complicated, so we just charge based on usage.*" Paga-se por segundo de máquina ligada, GB de disco provisionado e GB de tráfego de saída.

O que a nossa configuração custa — preço de gru

 **Corrigido:** a versão anterior usava o preço da região base. **Machine tem preço por região**, e São Paulo é mais cara.

Item	Preço em gru	Nosso caso
shared-cpu-1x com 1 GB	\$0,00000279/s (~\$7,23/mês)	1 máquina 24/7
Volume	\$0,15/GB/mês	1 GB = \$0,15
Egress América do Sul	\$0,04/GB	tráfego de painel, centavos
Certificado TLS	primeiros 10 grátis	\$0
IPv4 dedicado	\$2/mês	só se necessário

Total: ~\$7,50/mês.

O quanto São Paulo custa a mais, para referência:

shared-cpu-1x	IAD (mais barata)	GRU	Diferença
512 MB	\$0,00000123/s	\$0,00000156/s	+27%
1 GB	\$0,00000220/s	\$0,00000279/s	+27%
2 GB	\$0,00000413/s	\$0,00000524/s	+27%

Ou seja: a latência de São Paulo custa ~27% a mais de compute. Em dinheiro, ~\$1,50/mês.

Comparando com o que foi avaliado

Opção	Custo	Gerenciado?	São Paulo?
Fly.io	~\$7,50	✓	✓
VPS (Hostinger KVM 2)	~\$14 na renovação	✗	✓
Render Standard	\$25	✓	✗

✓ **Corrigido:** a frase anterior dizia que o Fly era "o único gerenciado e o único em São Paulo". Errado — o Render também é gerenciado, só não tem região no Brasil. O correto é: **o Fly é o único que combina ambiente gerenciado com São Paulo.**

Ainda assim, **preço não é o critério** — é latência. Se a medição não mostrar ganho, a escolha cai mesmo custando um terço.

● Consumo não tem teto — e o Fly NÃO oferece proteção

✓ **Corrigido** — este era o erro mais grave da versão anterior. Ela mandava "configurar limite de gasto e alerta". Isso não existe no Fly. A documentação oficial de gestão de custo diz, textualmente:

"We don't support billing alerts (yet), so budget accordingly."

E sobre as franquias gratuitas:

"Free allowances don't cap your bill... If you go over, we'll bill you."

Não há teto rígido, não há alerta, não há corte automático. O que dá para fazer é o que eles próprios recomendam:

1. **Conferir a fatura parcial no painel** ("current month to date bill") com regularidade
— é retrospectivo, não preventivo
1. **Orçar pelo pior caso**, ou seja, pelo custo de tudo ligado 24/7 — não contar com economia de hibernação (que a gente desligou de propósito, ver seção 6)
1. **Manter uma única Machine e não ligar autoscaling** — o controle real é rodar menos máquinas, ou menores
1. `billing@fly.io` em caso de cobrança inesperada

Isso é uma diferença concreta em relação a plano fixo, e precisa entrar na decisão com o nome certo: no Render você não pode gastar mais que o plano; no Fly, pode.

Outras notas de preço

- Não existe mais free tier, só um trial — conferir os detalhes ao criar a conta.
- Suporte pago começa em \$29/mês, mais caro que a infraestrutura inteira. O suporte da comunidade atende neste porte.

2. O que ele oferece de máquina

Tipo	vCPU	RAM possível
shared-cpu-1x a 8x	1 a 8	256 MB × N até 2 GB × N
performance-1x a 8x	1 a 8	2 GB × N até 8 GB × N

Nossa configuração é `shared-cpu-1x` com 1 GB. O teto desse tipo é 2 GB, então há para onde crescer sem trocar de categoria.

512 MB está descartado desde o começo: foi o que matou o container no Render Free durante o cron do TikTok, em 15/08.

3. ⚠ A pegadinha do "shared": 6,25% de um núcleo

Shared e performance rodam no **mesmo hardware, com o mesmo clock**. A diferença é quanto tempo de execução se recebe a cada período de 80 ms:

```
shared      ->  5 ms / 80 ms = 6,25% de um núcleo (sustentado)
performance -> 80 ms / 80 ms = 100%
```

Mas ele acumula crédito. O tempo ocioso vira saldo de burst, até 500 segundos de CPU cheia guardados. Estourou o saldo, a máquina é **estrangulada nos 6,25%** até recarregar. Em máquinas maiores as cotas somam: `shared-cpu-2x` recebe 10 ms por período.

Por que isso importa para o NEXO

✅ **Corrigido** — erro de análise da versão anterior. Ela dizia que os syncs "queimam saldo" porque duram 20–60 s. Duração não é consumo de CPU. Os nossos syncs passam a maior parte do tempo *esperando* resposta da Amazon, do Mercado Livre, do TikTok e do Supabase — isso é espera de rede, que praticamente não gasta processador.

O que realmente consome CPU é o **parsing e a materialização** dos dados recebidos, que é uma fração pequena desse tempo. Ou seja: o cenário é bem mais favorável ao `shared-cpu-1x` do que a versão anterior deste doc sugeria.

A referência que tranquiliza: o Render Free entrega **0,1 CPU sustentado e zero burst**, e o app sobrevive nele hoje. O Fly dá um pouco menos de base e 500 s de rajada que o Render nunca deu.

🔥 **Mas segue sendo medição, não premissa.** Só o painel de throttling responde. Se o saldo acabar com frequência, o caminho é `performance-1x` — e aí o custo sobe muito, a vantagem de preço evapora e a **VPS volta a fazer sentido**.

4. ⚠ A pegadinha do volume: disco local, sem réplica

Documentação do Fly: um volume é *"uma fatia de um NVMe no mesmo servidor físico da Machine"*. Eles comparam com o disco interno de um notebook.

Compartilhar entre máquinas	✗ um volume, uma máquina
Replicação	✗ nenhuma — se o NVMe falhar, a aplicação cai
Snapshot	diário automático, 5 dias (configurável 1–60)
Encolher	✗ só dá para aumentar
Tamanho máximo	500 GB

A própria documentação avisa que o snapshot **não deve ser o backup principal**.

✅ **Corrigido:** a versão anterior citava a recomendação deles de "*provisionar pelo menos dois volumes*" como se fosse a solução. **Não é** — volumes **não se replicam entre si**. Dois volumes só ajudam se houver **duas Machines** e **alguma estratégia de replicação de dados** (LiteFS, ou o dado morar num Postgres gerenciado). Provisionar um segundo volume sozinho não compra disponibilidade nenhuma.

O ponto fraco de verdade

`DATA_DIR` guardando contas OAuth e custos em disco local é a maior fragilidade desta fase — mais séria que CPU ou preço.

Para um piloto é aceitável, **com backup**. Mas **esses dados precisam migrar para o Postgres antes de o NEXO depender definitivamente do Fly**. Isso vale igualmente no Render e em VPS — não é defeito do Fly, é dívida nossa que o Fly torna mais visível.

5. O que muda no dia a dia

Não existe painel para configurar infraestrutura. É CLI (`fly`) e o arquivo `fly.toml` , versionado no repo. Para nós é melhor — configuração revisável junto do código — mas é diferente do Render, onde se clica.

6. As duas configurações que não podem ser esquecidas

Ambas já estão no `fly.toml` do repo, com comentário explicando.

```
auto_stop_machines = false
```

O Fly hiberna máquina ociosa por padrão, e é daí que vem boa parte da economia da plataforma. **A gente desligou de propósito:** o cache do NEXO vive na memória do processo ([ADR-002](#)) e a conciliação de tarifas roda em background. Máquina que hiberna perde o cache e mata trabalho em andamento — seria reintroduzir, por configuração, o mesmo problema que fez a Vercel ser rejeitada.

Consequência assumida: **pagamos o mês cheio**. Os ~\$7,50 já refletem isso — e é também o que os próprios docs mandam fazer ao orçar (pelo custo "always-on").

```
[mounts] com DATA_DIR
```

O app grava custos e contas OAuth em disco. Sem volume montado, **cada deploy apaga esses dados**.

7. Como subir

Detalhes de build e das pegadinhas do Docker em [docker.md](#).

```
# 1. instalar o CLI e autenticar
curl -L https://fly.io/install.sh | sh
fly auth login

# 2. criar o volume ANTES do primeiro deploy
fly volumes create nexo_data --region gru --size 1

# 3. deploy
wsl bash scripts/fly-deploy.sh

# 4. segredos de runtime (lista completa em render.yaml)
fly secrets set DATABASE_URL=... LWA_CLIENT_SECRET=...
```

⚠ **Nunca rodar `fly deploy cru`.** Ele não passa os `--build-arg`, e a imagem sobe com as credenciais do Supabase vazias — o app funciona, o health check passa, e só a tela de login denuncia. O script existe para isso.

8. O piloto — e o que ele precisa provar

A decisão aprovada é testar, não migrar. O cutover só acontece depois que a medição sustentar a escolha.

Antes de subir

- [] Destruir o limite do Supabase (559 MB de 500 MB, subindo ~7 MB/dia)
- [] Registrar domínio próprio e cadastrar nas allowlists de Shopee e TikTok — sem

isso o OAuth dos dois canais quebra na troca de host, **em qualquer cenário**

- [] Conferir **capacidade em gru** e o que o trial inclui
- [] Aceitar conscientemente que **não há teto de gasto**, e definir uma rotina de

conferir a fatura parcial no painel

O piloto

Uma máquina `shared-cpu-1x` de 1 GB, **autostop desligado, sem autoscaling**, com o Render servindo produção o tempo todo, rodando todos os syncs por pelo menos uma semana.

O que medir antes de trocar o DNS

Medida	Por que decide
Latência contra o Render	É a justificativa inteira. Não melhorou, decisão cai
Saldo de burst e throttling	Se acabar sempre, <code>shared-cpu-1x</code> não serve
Memória	512 MB já matou o app uma vez
Persistência do volume entre deploys	<code>DATA_DIR</code> não pode sumir
Custo parcial no painel	Única proteção que existe

Se a máquina compartilhada aguentar, o Fly resolve por ~\$7,50. Se o burst acabar sempre e for preciso `performance-1x`, a vantagem de preço encolhe muito e a VPS volta a **fazer mais sentido** — por isso a decisão de cutover fica para depois da medição, não agora.

Relacionado: [ADR-015](#) · [docker.md](#) · [infra-decisao-hospedagem.md](#)