

Fly.io — o que é, o que custa e o que precisa saber antes de decidir

Levantado em 19/08/2026 direto da documentação oficial de preços, de sizing de máquina, de CPU e de volumes. A decisão de usar está no [ADR-015](#); este doc é a explicação de apoio.

Em uma frase

Micro-VMs cobradas por segundo, em **São Paulo**, rodando a nossa imagem Docker, por **~\$7/mês**, sem ninguém precisar administrar servidor.

1. O modelo de cobrança: não existe plano

É **pay-as-you-go** puro. Nas palavras deles: *"Plans get complicated, so we just charge based on usage."* Você paga por segundo de máquina ligada, GB de disco provisionado e GB de tráfego de saída.

O que a nossa configuração custa

Item	Preço	Nosso caso
<code>shared-cpu-1x</code> com 1 GB	\$0,00000228/s (~\$5,92/mês)	1 máquina 24/7
Volume	\$0,15/GB/mês	1 GB = \$0,15
Egress América do Sul	\$0,04/GB	tráfego de painel, centavos
Certificado TLS	primeiros 10 grátis	\$0
IPv4 dedicado	\$2/mês	só se necessário (compartilhado é grátis)

Total: ~\$6 a \$8/mês.

Comparando com o que foi avaliado

Opção	Custo	Gerenciado?	São Paulo?
Fly.io	~\$7	✓	✓
VPS (Hostinger KVM 2)	~\$14 na renovação	✗	✓
Render Standard	\$25	✓	✗

O Fly é o mais barato dos três, o único gerenciado e o único em São Paulo. Ainda assim, **preço não é o critério da decisão** — é latência. Se a medição não mostrar ganho, a escolha cai mesmo custando um terço.

⚠ Consumo não tem teto

Plano fixo protege você de você mesmo; consumo não. Um loop errado, um pico de tráfego ou um volume grande provisionado por engano vão para a fatura.

Configurar limite de gasto e alerta antes do primeiro deploy. É requisito, não sugestão.

Outras notas de preço

- Não existe mais free tier, só um trial — conferir os detalhes ao criar a conta.
- Suporte pago começa em \$29/mês (Standard), mais caro que a infraestrutura inteira.

O suporte da comunidade atende neste porte.

2. O que ele oferece de máquina

Tipo	vCPU	RAM possível
shared-cpu-1x a 8x	1 a 8	256 MB × N até 2 GB × N
performance-1x a 8x	1 a 8	2 GB × N até 8 GB × N

Nossa configuração é `shared-cpu-1x` com 1 GB. O teto desse tipo é 2 GB, então há para onde crescer sem trocar de categoria.

512 MB está descartado desde o começo: foi o que matou o container no Render Free durante o cron do TikTok, em 15/08.

3. ⚠ A pegadinha do "shared": 6,25% de um núcleo

Esta é a parte que ninguém lê e depois estranha.

Shared e performance rodam no **mesmo hardware, com o mesmo clock**. A diferença é quanto tempo de execução você recebe a cada período de 80 ms:

```
shared      ->  5 ms / 80 ms = 6,25% de um núcleo (sustentado)
performance -> 80 ms / 80 ms = 100%
```

Mas ele acumula crédito. O tempo ocioso vira saldo de burst, até 500 segundos de CPU cheia guardados. Aplicação que fica quieta e trabalha em rajadas — o perfil exato de um painel — vive bem assim. Estourou o saldo, a máquina é estrangulada nos 6,25% até recarregar.

Em máquinas maiores as cotas somam: `shared-cpu-2x` recebe 10 ms por período.

Por que isso importa para o NEXO

Os syncs são o que consome. O cron bate a cada 5 minutos, cada sync tem orçamento de 20–60 s e a conciliação de tarifas roda em background dentro do web. Isso queima saldo.

A referência que tranquiliza: o Render Free entrega 0,1 CPU sustentado e zero burst, e o app sobrevive nele hoje. O Fly dá um pouco menos de base e 500 s de rajada que o Render nunca deu. Para este perfil, tende a ser melhor.

🚧 Mas é medição, não premissa. Conferir o saldo de burst depois do deploy antes de declarar que `shared-cpu-1x` serve. Se estourar com frequência, o caminho é `performance-1x` — e aí o custo sobe muito e a comparação com o Render Standard volta a ficar parelha.

4. ⚠ A pegadinha do volume: disco local, sem réplica

Documentação do Fly: um volume é "uma fatia de um NVMe no mesmo servidor físico da Machine". Eles comparam com o disco interno de um notebook.

Compartilhar entre máquinas	❌ um volume, uma máquina
Replicação	❌ nenhuma — se o NVMe falhar, a aplicação cai
Recomendação deles	provisionar pelo menos dois volumes por app
Snapshot	diário automático, 5 dias (configurável 1–60)
Encolher	❌ só dá para aumentar
Tamanho máximo	500 GB

A própria documentação avisa que o snapshot **não deve ser o backup principal**.

Nossa topologia — 1 máquina, 1 volume — é exatamente o arranjo que eles desaconselham.

Aceito nesta fase, porque o `DATA_DIR` guarda contas OAuth (reconectáveis por re-OAuth) e custos. Mas reforça uma conclusão que já estava no ADR-015: **esse dado deveria morar no Postgres, não em disco local**. Isso vale igualmente no Fly, no Render e numa VPS — não é defeito do Fly.

5. O que muda no dia a dia

Não existe painel para configurar infraestrutura. É CLI (`fly`) e o arquivo `fly.toml` , versionado no repo. Para nós é melhor — a configuração fica revisável junto do código — mas é diferente do Render, onde se clica.

6. As duas configurações que não podem ser esquecidas

Ambas já estão no `fly.toml` do repo, com comentário explicando.

```
auto_stop_machines = false
```

O Fly hiberna máquina ociosa por padrão, e é daí que vem boa parte da economia da plataforma. **A gente desligou de propósito**: o cache do NEXO vive na memória do processo ([ADR-002](#)) e a conciliação de tarifas roda em background. Máquina que hiberna perde o cache e mata trabalho em andamento — seria reintroduzir, por configuração, o mesmo problema que fez a Vercel ser rejeitada.

Consequência assumida: **pagamos o mês cheio**. Os ~\$6 já refletem isso.

```
[mounts] com DATA_DIR
```

O app grava custos e contas OAuth em disco. Sem volume montado, **cada deploy apaga esses dados**.

7. Como subir

Detalhes de build e das pegadinhas do Docker em [docker.md](#) .

```
# 1. instalar o CLI e autenticar
curl -L https://fly.io/install.sh | sh
fly auth login

# 2. criar o volume ANTES do primeiro deploy
fly volumes create nexo_data --region gru --size 1

# 3. deploy
wsl bash scripts/fly-deploy.sh

# 4. segredos de runtime (lista completa em render.yaml)
fly secrets set DATABASE_URL=... LWA_CLIENT_SECRET=...
```

⚠ **Nunca rodar `fly deploy cru`.** Ele não passa os `--build-arg`, e a imagem sobe com as credenciais do Supabase vazias — o app funciona, o health check passa, e só a tela de login denuncia. O script existe para isso.

8. Checklist antes de decidir

- [] Configurar limite de gasto e alerta (modelo sem teto)
- [] Conferir capacidade na região `gru` — regiões brasileiras costumam operar cheias
- [] Conferir o que o `trial` inclui e quando a cobrança começa
- [] Registrar domínio próprio e cadastrar nas allowlists de Shopee e TikTok — sem

isso o OAuth dos dois canais quebra na troca de host, em qualquer cenário

E depois de subir, duas medições que decidem se a escolha se sustenta:

- [] **Latência contra o Render.** É a justificativa inteira da mudança. Se não melhorar,

a decisão cai.

- [] **Saldo de burst de CPU.** Se os syncs estourarem com frequência,

`shared-cpu-1x` não serve.

Relacionado: [ADR-015](#) · [docker.md](#) · [infra-decisao-hospedagem.md](#)